

Urban Health ABM

Demograficzna symulacja populacji Polski
z modelem dynamicznego ryzyka chorób przewlekłych

Szczegółowe notatki towarzyszące prezentacji

OPIEKUNOWIE dr inż. Franciszek Rakowski
 dr Jan Kisielewski
 Interdyscyplinarne Centrum Modelowania Matematycznego i Komputerowego UW

ZESPÓŁ **Anna Strugielska** (kierownik)
 Weronika Dąbrowska
 Magdalena Jarońska
 Wojciech Ofiara

Dokument zawiera kompletne wyjaśnienie projektu: motywację, źródła danych, architekturę kodu, formalizm matematyczny modelu Coxa wraz z wyprowadzeniem wszystkich wzorów, opis czynników ryzyka, metodologię kalibracji i gridsearchu, walidację oraz wnioski. Przeznaczony jako materiał wspierający prezentację oraz jako referencja do pytań szczegółowych.

Spis treści

1	Wprowadzenie	3
1.1	Czym jest Agent-Based Model (ABM)?	3
1.2	Motywacja projektu	3
1.3	Cele projektu	4
2	Źródła danych	5
2.1	Dane demograficzne	5
2.1.1	GUS Polska 2021 — Tablice Trwania Życia	5
2.1.2	Rozkład wiekowy — Spis Powszechny GUS 2021	5
2.1.3	ASFR — wiekowe stopy płodności GUS	5
2.1.4	Program Białystok+	6
2.2	Dane epidemiologiczne	6
3	Architektura modelu	7
3.1	Klasy obiektowe	7
3.2	Struktura danych: Dict[int, Citizen]	7
3.3	Pętla symulacji	7
4	Demografia bazowa	9
4.1	Lookup śmiertelności — algorytm floor bracket	9
4.2	Lookup płodności	9
4.3	Wskaźniki agregowane: CBR, CDR, TFR, NGR	9
4.3.1	Crude Birth Rate (surowy współczynnik urodzeń)	9
4.3.2	Crude Death Rate (surowy współczynnik zgonów)	10
4.3.3	Natural Growth Rate	10
4.3.4	Relacja $CBR \leftrightarrow TFR$	10
5	Model dynamicznego ryzyka — Cox Proportional Hazards	11
5.1	Motywacja: dlaczego Cox?	11
5.2	Formalizm matematyczny	11
5.2.1	Miesięczny przyrost hazardu	11
5.2.2	Akumulacja (cumulative hazard)	11
5.2.3	Inicjacja choroby (Poisson approximation)	12
5.2.4	Mortality z Cox-multiplier	12
5.3	Bazowe parametry hazardu	12
5.4	Macierz $\beta = \ln(HR)$	13
5.4.1	Multiplikatywność RF	13
5.5	Pełny przykład obliczeniowy	13
5.6	Bezpieczniki numeryczne	14
6	Czynniki ryzyka — inicjalizacja i opis	15
6.1	Lista 7 czynników ryzyka	15
6.2	Inicjalizacja wg wieku	15
6.3	Wpływ aplikacji interaktywnej	15

7	Gridsearch — optymalizacja parametrów	16
7.1	Cel	16
7.2	Funkcja oceny (score)	16
7.3	Trzy tryby gridsearch	16
7.3.1	Tryb 1 — Proxy analityczny	16
7.3.2	Tryb 2 — ABM dla piramid	16
7.3.3	Tryb 3 — Pełny ABM 12×12	17
7.4	Reguła stabilności — proxy vs ABM	17
7.4.1	Proxy — liniowa reguła	17
7.4.2	ABM — nieliniowa krzywa nasycenia	17
7.4.3	Dlaczego proxy się myli?	17
7.5	Wyniki kluczowe	17
8	Kalibracja i walidacja	18
8.1	Sanity check — spójność modelu z parametrami	18
8.2	Porównanie z GUS	18
8.3	Historia poprawek	18
8.3.1	Poprawka 1: odwrócona tabela śmiertelności kobiet (krytyczna)	19
8.3.2	Poprawka 2: zbyt niskie TFR (0,68 zamiast 1,26)	19
8.3.3	Poprawka 3: rozkład wiekowy nie sumował się do 1,0	19
8.3.4	Poprawka 4: lookup śmiertelności — nearest zamiast floor	19
8.3.5	Poprawka 5: zbyt silny wpływ chorób na śmiertelność	19
8.3.6	Poprawka 6: zbyt silna redukcja płodności przez choroby	19
8.3.7	Poprawka 7 (kluczowa): dodanie modelu Coxa + refaktor 3→2 chorób	19
9	Aplikacja interaktywna (Streamlit)	20
9.1	Funkcjonalność	20
9.1.1	Kontrolki	20
9.1.2	Gotowe scenariusze	20
9.1.3	Wyniki i wizualizacje	20
9.2	Przykładowe przypadki użycia	20
9.2.1	Kampania ograniczania palenia	20
9.2.2	Interwencja lifestyle’owa	21
10	Wnioski	22
10.1	Wnioski demograficzne	22
10.2	Wnioski epidemiologiczne	22
10.3	Wnioski metodologiczne	22
11	Ograniczenia i przyszłe rozszerzenia	24
11.1	Aktualne ograniczenia	24
11.2	Możliwe rozszerzenia	24
12	Technologie i implementacja	25
12.1	Stos technologiczny	25
12.2	Dlaczego <code>random.Random</code> , a nie <code>numpy.random</code> ?	25
12.3	Reproducibility	25
13	Bibliografia i źródła	26

1 Wprowadzenie

1.1 Czym jest Agent-Based Model (ABM)?

Agent-Based Model to klasa modeli symulacyjnych, w której zachowanie systemu wyłania się z indywidualnych decyzji wielu autonomicznych *agentów*. W odróżnieniu od klasycznych modeli makro (np. równań różniczkowych opisujących liczebność populacji jako pojedynczą zmienną), ABM utrzymuje pełną **heterogeniczność** populacji.

W naszym projekcie agentem jest *mieszkaniec* populacji syntetycznej. Każdy mieszkaniec posiada:

- unikalny identyfikator (*id*),
- wiek (mierzony w miesiącach, nie w latach — dla precyzji w pętli miesięcznej),
- płeć biologiczną (*male* lub *female*),
- przynależność do gospodarstwa domowego i strefy geograficznej,
- zestaw chorób przewlekłych (CVD, Lung Cancer),
- siedem czynników ryzyka (*risk factors*, RF),
- słownik *skumulowanego hazardu biologicznego* $H_{cum,d}$ dla każdej choroby d — biologiczną pamięć agenta.

Dlaczego ABM, a nie model makro? ABM pozwala na obserwację efektów emergentnych — zachowań populacji wynikających z heterogeniczności jednostek. Można dokładnie śledzić piramidy wiekowe, wielochorobowość i nierówności zdrowotne w sposób niedostępny w zagregowanych modelach ODE/PDE.

1.2 Motywacja projektu

Polska demografia jest **deficytowa**. Tabela 1 przedstawia kluczowe wskaźniki dla 2021 roku.

Wskaźnik	Polska 2021	Stan zastępowalności
TFR (Total Fertility Rate)	1,26	2,10
CBR (Crude Birth Rate)	8,5‰	—
CDR (Crude Death Rate)	13,5‰	= CBR
NGR (Natural Growth Rate)	−5,0‰/rok	≥ 0

Tabela 1: Wskaźniki demograficzne Polski 2021 wg GUS.

Przy niezmiennych warunkach (TFR poniżej progu zastępowalności pokoleń, ujemny przyrost naturalny) populacja zmniejsza się rocznie o około 5‰. W horyzoncie 50 lat oznacza to deficyt rzędu kilkudziesięciu procent. Pytania badawcze projektu:

1. Jaka kombinacja płodności i śmiertelności daje stabilną populację?
2. Jak czynniki ryzyka kształtują strukturę populacji w 50 lat?
3. Jaki efekt miałyby hipotetyczna kampania antynikotynowa lub interwencja na poziomie lifestyle?

1.3 Cele projektu

1. Zbudować pełny ABM dla populacji 50 000 agentów $\times$ 50 lat.
2. Skalibrować model demograficzny do danych GUS 2021 tak, aby przy mnożnikach $FM = MM = 1,0$ uzyskać realistyczne CBR, CDR i TFR.
3. Wdrożyć Cox Proportional Hazards z biologiczną pamięcią agenta — akumulacja szkód z ekspozycji na RF w czasie życia.
4. Wykonać gridsearch w przestrzeni (FM, MM) i odnaleźć regułę stabilności populacji.
5. Stworzyć aplikację interaktywną (Streamlit) z suwakami dla 7 czynników ryzyka, umożliwiającą eksperymentowanie ze scenariuszami.
6. Wyciągnąć wnioski demograficzne, epidemiologiczne i metodologiczne.

2 Źródła danych

Model opiera się na dwóch filarach: *demografii* (dane populacyjne z Polski) oraz *epidemiologii* (Hazard Ratios z literatury naukowej).

2.1 Dane demograficzne

2.1.1 GUS Polska 2021 — Tablice Trwania Życia

Tablice Trwania Życia podają roczne prawdopodobieństwa zgonu q_x w funkcji wieku x i płci. W naszym modelu przeliczamy je na prawdopodobieństwa *miesięczne*. Tabela 2 prezentuje wybrane wartości.

Wiek	Mężczyźni q_x^m	Kobiety q_x^f	Stosunek M/K
0	0,000373	0,000291	1,28
20	0,000042	0,000012	3,5
40	0,000167	0,000067	2,5
60	0,001375	0,000583	2,4
70	0,003292	0,001833	1,8
80	0,007658	0,005375	1,4
90	0,018333	0,013750	1,3

Tabela 2: Miesięczne prawdopodobieństwo zgonu q_x z GUS Polska 2021 (wartości skrócone do wybranych wieków).

Ważna obserwacja: mężczyźni mają wyższą śmiertelność w *każdym* przedziale wiekowym. Największa nadumieralność męska występuje w wieku 20–40 lat (wypadki, alkohol), gdzie stosunek dochodzi do 3,5x. Z wiekiem stosunek maleje, ale pozostaje powyżej 1.

2.1.2 Rozkład wiekowy — Spis Powszechny GUS 2021

Populacja syntetyczna jest generowana z polskim rozkładem wiekowym (Tabela 3). Wartości są normalizowane tak, aby sumowały się do 1.

Przedział wieku	Udział
0–9	9,4 %
10–19	9,8 %
20–29	10,4 %
30–39	14,3 %
40–49	13,5 %
50–59	13,7 %
60–69	12,8 %
70–79	9,7 %
80–89	5,1 %
90+	1,3 %

Tabela 3: Rozkład wiekowy populacji Polski 2021 (suma $\approx 1,000$).

2.1.3 ASFR — wiekowe stopy płodności GUS

Age-Specific Fertility Rate (ASFR) podaje roczną liczbę urodzeń na kobietę w danym przedziale wieku. Tabela 4 pokazuje wartości używane w modelu.

Wiek	ASFR (roczna)	Miesięczna
15–19	0,011	0,00092
20–24	0,041	0,00342
25–29	0,081	0,00675
30–34	0,082	0,00683
35–39	0,034	0,00283
40–44	0,007	0,00058
45–49	0,0003	0,000025

Tabela 4: Wiekowe stopy płodności GUS Polska 2021. Szczyt: 25–34 lat.

Całkowita dzietność (Total Fertility Rate):

$$\text{TFR} = \sum_{\text{age}=15}^{49} \text{ASFR}(\text{age}) \cdot \Delta\text{age} = (0,011 + 0,041 + \dots + 0,0003) \cdot 5 \approx 1,28 \quad (1)$$

2.1.4 Program Białystok+

Program *Białystok+* dostarcza kohortowych danych medycznych z populacji polskiej miasta Białystok. Dane obejmują pomiary BMI, ciśnienia krwi, cholesterolu, prevalencje palenia oraz przypadków chorób sercowo-naczyniowych. W naszym modelu wykorzystaliśmy te dane do:

- kalibracji wiekowych profili prevalencji RF (krzywe inicjacji),
- walidacji wyników modelu względem rzeczywistych pomiarów,
- ugruntowania bazowych λ_0 dla każdej choroby.

2.2 Dane epidemiologiczne

Hazard Ratios (HR) używane w modelu pochodzą z najpoważniejszych źródeł kardiologicznych i onkologicznych:

Risk Factor	Choroba	Źródło
smoking	CVD	Framingham Heart Study, wytyczne ESC
smoking	Lung Cancer	CDC, IARC (International Agency for Research on Cancer)
obesity	CVD	Framingham, American Heart Association
hypertension	CVD	Wytyczne ESC (European Society of Cardiology)
high cholesterol	CVD	Framingham, ATP III (Adult Treatment Panel III)
physical inactivity	CVD	WHO, AHA
family history	CVD/Cancer	Framingham, BRCA studies
alcohol abuse	CVD	Meta-analiza prospektywnych kohortowych

Tabela 5: Źródła dla Hazard Ratios.

Synteza danych. ABM bierze *demografię* z GUS i Białystoku+ (skala populacji), *epidemiologię* z literatury naukowej (skala indywidualna). Nakładamy je za pomocą modelu Coxa Proportional Hazards.

3 Architektura modelu

3.1 Klasy obiektowe

Model jest napisany w Pythonie 3.12 z paradygmatu zorientowanego obiektowo. Pięć klas:

- **Citizen** — pojedynczy agent populacji. Posiada wiek, płeć, choroby, RF, biologiczną pamięć Coxa.
- **Household** — gospodarstwo domowe. Przechowuje *listę ID* członków (nie obiekty — aby uniknąć cykli).
- **Zone** — strefa geograficzna. Cztery strefy w modelu, różniące się jakością powietrza, dostępem do opieki i gęstością.
- **DiseaseModel** — definicje chorób, disability weights, prevalencje, oraz cztery macierze parametrów modelu Coxa.
- **SimulationEngine** — główny silnik. Zarządza populacją, gospodarstwami, statystykami; wykonuje pętlę miesięczną.

3.2 Struktura danych: Dict[int, Citizen]

Populacja jest przechowywana jako słownik `citizens: Dict[int, Citizen]`. Wybór tej struktury nie jest przypadkowy:

Kryterium	Dict[int, Citizen]	List[Citizen]
Lookup po ID	$O(1)$	$O(n)$
Usunięcie martwych	nie trzeba (flaga <code>alive</code>)	drogie przesunięcia
Nowe narodziny	<code>citizens[id] = newborn</code>	<code>append()</code>
Stabilność referencji	stałe ID	indeksy przesuwają się

Tabela 6: Porównanie struktur danych.

Kluczowy szczegół. Martwi agenci *nie są usuwani* ze słownika. Otrzymują flagę `alive = False`. Dzięki temu:

- gospodarstwo może sprawdzić czy członek żyje bez `KeyError`,
- statystyki retrospektywne są możliwe,
- unika się kosztownej przebudowy słownika.

3.3 Pętla symulacji

Każda iteracja reprezentuje jeden miesiąc (1 rok = 12 iteracji). Pseudokod:

```

1 for month in range(600): # 50 lat x 12 miesięcy
2     age_all() # każdy agent: age_months += 1
3     handle_deaths() # 3-fazowy model Coxa:
4         # a) akumulacja H_cum dla każdej choroby
5         # b) inicjacja choroby z  $P = 1 - \exp(-\text{delta}_h)$ 
6         # c) mortality =  $q_x * \text{cox\_mult} * MM$ 
7     handle_births() # ASFR * FM * redukcja_chorob
8     handle_household_splits() # dorośli 25+ opuszczają domy

```



```
9     update_health_states() # progresja stanów zdrowia
0     if month % 12 == 0:
1         collect_yearly_stats() # piramida wieku, populacja itp.
```

Skala obliczeń: 50 000 agentów $\times$ 600 iteracji $\times$ ≈ 6 podkroków per agent $\approx 1,8 \times 10^8$ operacji na pojedynczą symulację. Czas wykonania: ~ 90 sekund. Gridsearch 144 punktów przy zrównoleglnieniu na 10 rdzeniach: ~ 50 minut.

4 Demografia bazowa

4.1 Lookup śmiertelności — algorytm floor bracket

Funkcja `_get_mortality_rate(age, sex)` znajduje wiekowy bracket w tabeli śmiertelności. Krytyczny szczegół: używamy *floor*, nie *nearest*.

$$q_x(\text{age}, \text{sex}) = \text{MORTALITY_TABLE}[\text{bracket}(\text{age})][\text{sex}]$$

$$\text{bracket}(\text{age}) = \max\{a \in \text{table_keys} : a \leq \text{age}\}$$

Przykład: agent w wieku 63 lat. Klucze tabeli: ..., 60, 65, 70, ...

- Floor: 60 (bo $60 \leq 63 < 65$). Stawka dla q_{60} . *Poprawne.*
- Nearest: 65 (odległość 2 vs 3). Stawka dla q_{65} . *Błąd, agent dostaje stawkę dla starszego bracketu.*

Tę poprawkę dodaliśmy podczas kalibracji — przed nią osoby w wieku 60–64 miały 53% wyższą śmiertelność niż powinny.

4.2 Lookup płodności

Analogicznie dla płodności — 5-letnie bracketu:

$$\text{ASFR}(\text{age}) = \begin{cases} \text{FERTILITY_TABLE}[\lfloor \text{age}/5 \rfloor \cdot 5] & \text{jeśli } 15 \leq \text{age} \leq 50 \\ 0 & \text{w przeciwnym razie} \end{cases}$$

Miesięczne prawdopodobieństwo urodzenia (po uwzględnieniu zmiennej FM = fertility multiplier oraz redukcji przez choroby):

$$P_{\text{birth, monthly}} = \frac{\text{ASFR}(\text{age})}{12} \cdot \text{FM} \cdot \text{disease_reduction}$$

$$\text{disease_reduction} = \max(1 - 0,02 \cdot n_{\text{cond}} - 0,04 \cdot \text{disability_score}, 0,7)$$

Limit 0,7 zapobiega temu, aby choroby zredukowały płodność do zera — empirycznie nawet kobiety z wieloma chorobami zachowują niemałą płodność.

4.3 Wskaźniki agregowane: CBR, CDR, TFR, NGR

4.3.1 Crude Birth Rate (surowy współczynnik urodzeń)

CBR mierzy liczbę urodzeń żywych na 1000 mieszkańców w ciągu roku.

$$\text{CBR} = \frac{B_{\text{rok}}}{N} \times 1000 \quad [\text{‰}]$$

gdzie B_{rok} — liczba urodzeń w roku, N — średnia populacja.

Wartości:

- Polska 2021 (GUS): $\text{CBR} \approx 8,5\text{‰}$
- Model po kalibracji (FM=1,0): $\text{CBR} = 8,30\text{‰}$ ✓

Ograniczenie. CBR jest *surowy* (crude), bo nie koryguje na strukturę wiekową. Społeczeństwo z większą frakcją kobiet w wieku 20–35 lat będzie miało wyższe CBR przy tej samej skłonności do rodzenia.

4.3.2 Crude Death Rate (surowy współczynnik zgonów)

$$\text{CDR} = \frac{D_{\text{rok}}}{N} \times 1000 \quad [\text{‰}]$$

Wartości:

- Polska 2021 (GUS): $\text{CDR} \approx 13,5\text{‰}$
- Model po kalibracji (MM=1,0): $\text{CDR} = 15,6\text{‰}$ (lekkie zawyżenie — patrz §8)

4.3.3 Natural Growth Rate

$$\text{NGR} = \text{CBR} - \text{CDR} \quad [\text{‰/rok}]$$

Wartości:

- Polska 2021: $\text{NGR} = 8,5 - 13,5 = -5,0\text{‰/rok}$
- Model (FM=MM=1,0): $\text{NGR} = 8,30 - 15,60 = -7,3\text{‰/rok}$

Wzrost populacji w horyzoncie 50 lat (proxy analityczny):

$$\text{score}(50) = \left(\left(1 + \frac{\text{NGR}}{1000} \right)^{50} - 1 \right) \times 100 \%$$

4.3.4 Relacja CBR↔TFR

CBR i TFR są powiązane przez frakcję kobiet w wieku rozrodczym:

$$\text{CBR} \approx \text{TFR} \cdot \frac{\text{frakcja kobiet 15–50}}{\text{długość okresu rozrodczego}} \approx \text{TFR} \cdot \frac{0,23}{35}$$

Weryfikacja: przy $\text{TFR} = 1,28$:

$$\text{CBR} \approx 1,28 \cdot \frac{0,23}{35} \approx 0,0084 = 8,4\text{‰}$$

co odpowiada wartości empirycznej z modelu (8,30‰). To samo równanie tłumaczy, dlaczego *flat-rate fertility* (jednakowa stopa dla wszystkich wieków) nie działa — bo urodzenia pochodzą tylko od ~23 % populacji.

5 Model dynamicznego ryzyka — Cox Proportional Hazards

To jest **rdzeń projektu** — przejście od statycznych mnożników mortality do dynamicznego modelu akumulacji ryzyka.

5.1 Motywacja: dlaczego Cox?

Pierwotna wersja modelu używała **stycznych mnożników mortality**: `risk_mult *= 1.1` dla palaczy, `*1.05` dla otyłych. Problemy tego podejścia:

- 30-letni palacz miał identyczne ryzyko jak 60-letni — co biologicznie nieprawdziwe (szkody akumulują się przez dziesięciolecia).
- Brak mechanizmu *dynamicznej inicjacji choroby* — agent albo miał chorobę od początku, albo nigdy.
- Brak *biologicznej pamięci* agenta — ekspozycja w młodości nie wpływała na ryzyko w starszym wieku inaczej niż przez stały mnożnik.

Po refaktorze model używa **Cox Proportional Hazards** z skumulowanym hazardem. Każdy agent ma "biologiczną pamięć" $H_{cum,d}$ rosnącą wraz z ekspozycją na RF.

5.2 Formalizm matematyczny

5.2.1 Miesięczny przyrost hazardu

Dla agenta w wieku a (lata) z risk factors $X = (X_1, \dots, X_7) \in \{0, 1\}^7$ i dla choroby $d \in \{\text{CVD}, \text{Lung Cancer}\}$:

$$\Delta h_d(a, X) = \lambda_{0,d} \cdot \exp(\gamma_{age,d} \cdot (a - 30)) \cdot \exp\left(\sum_{i=1}^7 \beta_{d,i} \cdot X_i\right)$$

Symbole:

- $\lambda_{0,d}$ — bazowy hazard miesięczny w wieku 30 lat (**BASELINE_HAZARD**); jest to ryzyko inicjacji choroby u "uśrednionej" osoby bez RF w referencyjnym wieku.
- $\gamma_{age,d}$ — tempo wzrostu hazardu z wiekiem (**AGE_HAZARD_GROWTH**); model Gompertza, gdzie hazard rośnie wykładniczo.
- $\beta_{d,i} = \ln(\text{HR}_{d,i})$ — log Hazard Ratio dla RF i względem choroby d (**HAZARD_BETA**).
- $X_i \in \{0, 1\}$ — czy agent ma risk factor i .

Konwencja $\beta = \ln(\text{HR})$ wynika z definicji modelu Coxa: w wykładniku $\exp(\sum \beta_i X_i)$ obecność $X_i = 1$ mnoży hazard przez $e^{\beta_i} = \text{HR}_i$. To zapewnia interpretowalność współczynników.

5.2.2 Akumulacja (cumulative hazard)

$$H_{cum,d}(T) = \sum_{t=0}^T \Delta h_d(t)$$

H_{cum} rośnie monotonicznie i reprezentuje **biologiczne uszkodzenie skumulowane**. Dwóch palaczy w wieku 60 lat może mieć różne H_{cum} jeśli jeden zaczął palić w 20 r.ż., a drugi w 40.

5.2.3 Inicjacja choroby (Poisson approximation)

Przy małym Δh , prawdopodobieństwo zdarzenia w pojedynczym kroku jest dobrze przybliżone przez:

$$P(\text{onset}_d \mid \text{not_yet_sick}) = 1 - \exp(-\Delta h_d(t))$$

Wyprowadzenie: dla procesu Poissona o intensywności Δh , prawdopodobieństwo *co najmniej jednego* zdarzenia w jednostce czasu wynosi $1 - e^{-\Delta h}$. Dla małych Δh : $1 - e^{-\Delta h} \approx \Delta h$.

W kodzie: jeśli $\text{rng.random}() < 1 - \exp(-\Delta h)$, to choroba zostaje aktywowana (`citizen.diseases[d] = 1`).

5.2.4 Mortality z Cox-multiplier

Mortality dla agentów z aktywnymi chorobami:

$$\begin{aligned} P_{\text{death}}(t) &= q_x(\text{age}, \text{sex}) \cdot \text{disease_mult} \cdot \text{cox_mult} \cdot \text{MM} \\ \text{disease_mult} &= 1 + 0,04 \cdot \text{disability_score} \\ \text{disability_score} &= \sum_d \mathbb{I}\{d \text{ active}\} \cdot \text{DW}_d \\ \text{cox_mult} &= \exp \left(\sum_d \gamma_d \cdot \min(H_{\text{cum},d}, \text{cap}) \right) \end{aligned}$$

gdzie:

- q_x — bazowa stopa GUS (z tabeli śmiertelności),
- DW_d — disability weight choroby ($\text{DW}_{\text{CVD}} = 0,25$, $\text{DW}_{\text{LC}} = 0,55$),
- γ_d — współczynnik MORTALITY_GAMMA (1,2 dla CVD, 2,5 dla LC),
- $\text{cap} = 1,5$ — limit zabezpieczający `exp()` przed wybuchem,
- MM — globalny mortality multiplier (zmienna sterująca gridsearchu).

5.3 Bazowe parametry hazardu

Choroba	λ_0 (mies.)	Roczny ekv.	γ_{age}	Czas podwojenia
CVD	$6,0 \times 10^{-5}$	0,72 %	0,06	~12 lat
Lung Cancer	$3,0 \times 10^{-6}$	0,036 %	0,075	~9 lat

Tabela 7: Bazowe parametry hazardu chorób.

Interpretacja: przy wieku 30 lat, bez żadnych RF, miesięczne prawdopodobieństwo inicjacji CVD wynosi 6×10^{-5} (czyli ok. 0,006 %). Przy wieku 70 lat, dalej bez RF, mnożnik wieku to $\exp(0,06 \cdot 40) = e^{2,4} \approx 11$, więc miesięczne ryzyko wzrasta do ~0,066 %.

Czas podwojenia hazardu (Gompertz):

$$T_{\text{podwojenia}} = \frac{\ln 2}{\gamma_{\text{age}}} \implies T_{\text{CVD}} = \frac{\ln 2}{0,06} \approx 11,55 \text{ lat}$$

Lung Cancer rośnie z wiekiem *szybciej* ($\gamma = 0,075$ vs $0,06$) — odzwierciedla biologię raka, gdzie dłuższa ekspozycja na karcynogeny + akumulacja mutacji somatycznych przyspiesza onet z wiekiem.

5.4 Macierz $\beta = \ln(\text{HR})$

Pełna macierz współczynników, pokazana jako β i HR dla intuicji:

Risk Factor	HR(CVD)	$\beta(\text{CVD})$	HR(LC)	$\beta(\text{LC})$
smoking	2,5	0,916	15,0	2,708
obesity	1,7	0,531	1,0	0,000
physical_inactivity	1,4	0,336	1,2	0,182
alcohol_abuse	1,3	0,262	1,3	0,262
high_cholesterol	2,0	0,693	1,0	0,000
hypertension_stage0	2,2	0,788	1,0	0,000
family_history	1,5	0,405	1,5	0,405

Tabela 8: Pełna macierz Hazard Ratios. Dominacja palenia w raku płuc: HR=15 jest największą wartością.

5.4.1 Multiplikatywność RF

Risk factors w modelu Coxa działają **multiplikatywnie**, nie addytywnie:

$$\text{Relative Risk} = \exp\left(\sum_i \beta_i X_i\right) = \prod_i \text{HR}_i^{X_i}$$

Przykład: palacz z otyłością. Względne ryzyko CVD:

$$\text{RR} = \exp(\beta_{\text{smok}} + \beta_{\text{ob}}) = \exp(0,916 + 0,531) = \exp(1,447) \approx 4,25$$

To samo otrzymujemy z $\text{HR}_{\text{smok}} \cdot \text{HR}_{\text{ob}} = 2,5 \cdot 1,7 = 4,25$.

Uwaga: podejście multiplikatywne nie zakłada interakcji między RF (czyli np. że palenie i otyłość wzajemnie się wzmacniają ponad zwykłą multiplikatywność). Jest to standardowe założenie modelu Coxa — proporcjonalność hazardów.

5.5 Pełny przykład obliczeniowy

Scenariusz: 60-letni mężczyzna z paleniem, wysokim cholesterolem i nadciśnieniem. Oblicz miesięczne ryzyko inicjacji CVD.

1. Bazowy hazard:

$$\lambda_{0,\text{CVD}} = 6,0 \times 10^{-5}$$

2. Współczynnik wieku (Gompertz):

$$\exp(\gamma_{\text{age}} \cdot (a - 30)) = \exp(0,06 \cdot 30) = e^{1,8} \approx 6,05$$

3. Modyfikator RF:

$$\exp(\beta_{\text{smok}} + \beta_{\text{chol}} + \beta_{\text{hyper}}) = \exp(0,916 + 0,693 + 0,788) = e^{2,397} \approx 10,99$$

4. **Wynik:**

$$\Delta h = 6,0 \times 10^{-5} \cdot 6,05 \cdot 10,99 \approx 3,99 \times 10^{-3}$$

5. **Porównanie z baseline (bez RF):**

$$\Delta h_{\text{baseline}} = 6,0 \times 10^{-5} \cdot 6,05 \approx 3,63 \times 10^{-4}$$

Mnożnik: $\Delta h / \Delta h_{\text{baseline}} = 11,0\times$ — agent ma 11-krotnie wyższe miesięczne ryzyko CVD.

6. **Prawdopodobieństwo onset:**

$$P(\text{onset}) = 1 - e^{-\Delta h} \approx 1 - 0,9960 = 0,40 \% \text{ miesięcznie}$$

W skali roku: $1 - (1 - 0,004)^{12} \approx 4,7 \%$.

5.6 **Bezpieczniki numeryczne**

W implementacji modelu zabezpieczamy się przed dwoma problemami:

- **Brak hazardu u dzieci.** Akumulacja H_{cum} nie zaczyna się przed wiekiem 18 lat:

$$\text{effective_age} = \max(\text{age}, 18)$$

Dzięki temu noworodki i dzieci nie nabywają hazardu (mimo że tabelaryczna q_x pozwala na śmiertelność dziecięcą).

- **Cap na H_{cum} w mortality.** W wykładniku $\exp(\sum \gamma_d H_{\text{cum},d})$ używamy:

$$\min(H_{\text{cum},d}, 1,5)$$

To zapobiega wybuchowi numerycznemu przy bardzo wysokim H_{cum} (np. palacz przez 50 lat).

6 Czynniki ryzyka — inicjalizacja i opis

6.1 Lista 7 czynników ryzyka

1. **smoking** — palenie tytoniu. Najsilniejszy RF dla raka płuc (HR=15), silny dla CVD (HR=2,5).
2. **obesity** — otyłość (BMI ≥ 30). Wpływa głównie na CVD (HR=1,7).
3. **physical_inactivity** — brak regularnej aktywności fizycznej.
4. **alcohol_abuse** — nadużywanie alkoholu (kryterium WHO: > 14 jednostek/tydz.).
5. **high_cholesterol** — hipercholesterolemia (cholesterol całkowity > 200 mg/dl). *Uwaga: była wcześniej traktowana jako choroba; refaktor przeniósł ją do RF.*
6. **hypertension_stage0** — nadciśnienie pre-clinical (SBP 120–139 lub DBP 80–89 mmHg).
7. **family_history** — pozytywny wywiad rodzinny (CVD/rak w pokrewieństwie pierwszego stopnia).

6.2 Inicjalizacja wg wieku

Każdemu agentowi przy tworzeniu populacji losujemy 7 RF z prawdopodobieństwami zależnymi od wieku, kalibrowanymi do danych GUS oraz programu Białystok+:

```

1 # Palenie (20-70 lat, peak w wieku 45)
2 smoking_prob = 0.25 * (1 - ((age - 45)**2 / 50**2))
3 smoking_prob = max(smoking_prob, 0.10)
4
5 # Otylosc (rosnie z wiekiem)
6 obesity_prob = 0.15 + (age - 20) * 0.008 # 5% -> 45%
7
8 # Brak aktywnosci fizycznej (rosnie z wiekiem)
9 inactivity_prob = 0.2 + (age - 20) * 0.005 # 10% -> 45%
10
11 # Naduzywanie alkoholu (uniform 20-65 lat)
12 alcohol_prob = 0.08
13
14 # Hipercholesterolemia (rosnie z wiekiem)
15 cholesterol_prob = (age - 20) * 0.006 # 1% -> 40%
16
17 # Nadciscnienie (rosnie po 30. r.z.)
18 hypertension_prob = (age - 30) * 0.008 # 1% -> 35%
19
20 # Historia rodzinna (stala, niezalezna od wieku)
21 family_history_prob = 0.15

```

6.3 Wpływ aplikacji interaktywnej

W aplikacji Streamlit użytkownik może modyfikować prevalencje RF za pomocą *mnożników* (0,0 do 3,0). Mnożnik 0,5 oznacza redukcję prevalencji o połowę (symulacja kampanii zdrowotnej); 1,5 — wzrost o 50 % (scenariusz pogorszenia). Te modyfikacje są stosowane do wzorów inicjalizacji:

$$P'_{RF}(\text{age}) = \min(P_{RF}(\text{age}) \cdot \text{slider_value}, 1,0)$$

7 Gridsearch — optymalizacja parametrów

7.1 Cel

Gridsearch przeszukuje przestrzeń dwóch parametrów — **fertility multiplier (FM)** i **mortality multiplier (MM)** — aby znaleźć punkty stabilności populacji.

Przestrzeń poszukiwań:

$$\text{FM} \in \{0,40, 0,59, \dots, 2,50\}, \quad \text{MM} \in \{0,30, 0,42, \dots, 1,60\}$$

Razem $12 \times 12 = 144$ kombinacji.

7.2 Funkcja oceny (score)

$$\text{score}(\text{FM}, \text{MM}) = \frac{N_{\text{final}} - N_{\text{init}}}{N_{\text{init}}} \times 100 \%$$

- $\text{score} > +2 \%$ — populacja rośnie (czerwony obszar na heatmapie),
- $-2 \% \leq \text{score} \leq +2 \%$ — stabilna (zielony/biały),
- $\text{score} < -2 \%$ — maleje (niebieski).

7.3 Trzy tryby gridsearch

7.3.1 Tryb 1 — Proxy analityczny

Plik: `grid_search_improved_v3_fixed.py`.

Używa matematycznego modelu proxy *bez uruchamiania ABM*, skalibrowanego na bazowych CBR/CDR:

$$\text{CBR}_{\text{eff}} = \text{BASE_CBR} \cdot \text{FM}, \quad \text{CDR}_{\text{eff}} = \text{BASE_CDR} \cdot \text{MM}$$

$$\text{NGR}_{\text{annual}} = \text{CBR}_{\text{eff}} - \text{CDR}_{\text{eff}}$$

$$\text{score}_{\text{proxy}} = \left((1 + \text{NGR}_{\text{annual}})^{50} - 1 \right) \times 100$$

gdzie $\text{BASE_CBR} = 0,00830$, $\text{BASE_CDR} = 0,01560$.

Charakterystyka:

- Czas: ~ 1 ms na kombinację, ~ 30 s na całą siatkę 12×12 .
- Założenie: linearna skala $\text{CBR} \propto \text{FM}$, $\text{CDR} \propto \text{MM}$.
- **Ograniczenie:** brak modelowania struktury wiekowej, brak feedback loops.

7.3.2 Tryb 2 — ABM dla piramid

Plik: `gridsearch_age_pyramids_analysis.py`.

Pełne symulacje ABM, ale tylko dla wybranych 21 punktów ($3 \times 3 + 3$ diagonale). Cel: generowanie piramid wieku do wizualnej inspekcji.

Czas: ~ 90 s na symulację $\times 21$ punktów = ~ 30 min (z parallel ~ 5 min).

7.3.3 Tryb 3 — Pełny ABM 12×12

Plik: `gridsearch_full_abm_no_rf.py`.

Uruchamia pełną symulację ABM dla każdego z 144 punktów siatki. Risk factors są wyłączone (`c.risk_factors = {rf: 0 ...}`) — celem jest izolowanie efektu samej demografii.

Czas: ~50 min z 10 rdzeniami.

7.4 Reguła stabilności — proxy vs ABM

Po analizie wyników okazuje się, że proxy i pełny ABM dają **istotnie różne** reguły stabilności.

7.4.1 Proxy — liniowa reguła

Z warunku $CBR_{\text{eff}} = CDR_{\text{eff}}$:

$$BASE_CBR \cdot FM = BASE_CDR \cdot MM$$

$$FM_{\text{proxy}}(MM) = \frac{BASE_CDR}{BASE_CBR} \cdot MM = 1,88 \cdot MM$$

7.4.2 ABM — nieliniowa krzywa nasycenia

Empirycznie:

$$FM_{\text{ABM}}(MM) \approx 1,50 + 0,36 \cdot \tanh(2 \cdot (MM - 0,4))$$

$$\lim_{MM \rightarrow \infty} FM_{\text{ABM}} \approx 2,05$$

7.4.3 Dlaczego proxy się myli?

1. **Brak struktury wiekowej.** Niska MM = długie życie = populacja się starzeje = mniej kobiet w wieku 15–50 = realne CBR rośnie *wolniej* niż FM sugeruje.
2. **Brak feedback loops.** Wczesne zgony kohorty rozrodczej zmniejszają przyszłą bazę reprodukcyjną. Proxy nie widzi tego efektu.
3. **Nieliniowa odpowiedź.** Przy bardzo wysokim FM i bardzo niskiej MM proxy daje absurdalne +122 % wzrostu. ABM ogranicza do +50 % — bo selekcja śmiertelnościowa i nasycenie struktury wiekowej działają jako ograniczniki.

Średnia bezwzględna różnica $|\Delta|$ między proxy a ABM dla całej siatki 144 punktów: **22,4 pp**. Lokalnie różnice dochodzą do ± 72 pp.

7.5 Wyniki kluczowe

Prawdziwy punkt stabilności (ABM): $FM \approx 1,93$, $MM \approx 1,01$ (score = $-0,88\%$).

FM	MM	Score proxy	Score ABM	Charakter
0,40	1,60	-66,5 %	-66,3 %	Silny spadek
1,93	1,01	+1,3 %	-0,88 %	Stabilny w ABM
2,12	1,13	-0,02 %	+7,2 %	Stabilny w proxy
2,50	1,00	+35,7 %	+33,1 %	Silny wzrost
2,50	0,30	+121,9 %	+50,1 %	Proxy absurd

Tabela 9: Wybrane punkty siatki gridsearch.

8 Kalibracja i walidacja

8.1 Sanity check — spójność modelu z parametrami

Aby zweryfikować, że model Coxa został zaimplementowany poprawnie, porównujemy empiryczne stosunki ryzyka między grupami (palacze vs niepalący) z teoretycznymi HR z macierzy β .

Test: 5 000 agentów przez 10 lat.

Grupa	n	H_{cum} CVD	Prev CVD	H_{cum} LC	Prev LC
Palacze	659	0,177	29,7 %	0,0423	6,83 %
Niepalący	4204	0,063	16,7 %	0,0027	2,14 %
Stosunek	—	2,8×	—	16×	—

Tabela 10: Sanity check — porównanie palacze vs niepalący.

Weryfikacja:

- CVD: stosunek H_{cum} palacze/niepalący = 2,8×, blisko HR=2,5 z macierzy β . ✓
- Lung Cancer: stosunek = 16×, niemal dokładnie zgodnie z HR=15 (różnica 7 % w granicy błędu statystycznego). ✓

Wniosek: model jest matematycznie spójny z parametrami wejściowymi. Każda zmiana w macierzy β przełoży się na proporcjonalne zmiany w prevalencjach.

8.2 Porównanie z GUS

Wskaźnik	Model (FM=MM=1,0)	GUS 2021	Zgodność
CBR	8,30‰	8,5‰	✓ (98 %)
CDR	15,6‰	13,5‰	~ (115 % — patrz uwaga)
TFR	1,28	1,26	✓ (101 %)

Tabela 11: Porównanie wskaźników modelu z GUS Polska 2021.

Uwaga o CDR. Model ma nieco zawyżony CDR (15,6 vs 13,5). Wynika to z tego, że tabele q_x z GUS dotyczą całej populacji (włącznie z osobami chorymi), a w modelu domyślna śmiertelność nie koryguje w dół dla efektu "zdrowej populacji syntetycznej". To akceptowalne odchylenie — ważne, że punkt stabilności pozostaje wewnątrz siatki parametrów.

8.3 Historia poprawek

Podczas kalibracji wykryliśmy i naprawiliśmy szereg błędów. Lista najważniejszych:

8.3.1 Poprawka 1: odwrócona tabela śmiertelności kobiet (krytyczna)

Problem. W oryginalnej tabeli kobiety 65–84 lat miały śmiertelność $2\times$ wyższą niż mężczyźni — dokładnie odwrotnie do rzeczywistości.

Skutek. Kobiety umierały za szybko na starość, populacja kurczyła się dramatycznie, wszystkie scenariusze gridsearch dawały -43% do -83% .

Naprawa. Zastąpienie wartości danymi z GUS 2021. Stosunek M/K = 1,8 dla wieku 65–75 (mężczyźni $\sim 2\times$ wyższa q_x).

8.3.2 Poprawka 2: zbyt niskie TFR (0,68 zamiast 1,26)

Oryginalna tabela ASFR dawała TFR $\approx 0,61$ zamiast polskich 1,26. Naprawa przez aktualizację ASFR z GUS 2021.

8.3.3 Poprawka 3: rozkład wiekowy nie sumował się do 1,0

Sumował się do 0,565. Po normalizacji osoby 90+ stanowiły 1,77% populacji zamiast 1,3%. Naprawa: zaktualizowanie do GUS 2021.

8.3.4 Poprawka 4: lookup śmiertelności — nearest zamiast floor

Patrz §4.1. Osoby w wieku 60–64 miały 53% wyższą śmiertelność niż powinny.

8.3.5 Poprawka 5: zbyt silny wpływ chorób na śmiertelność

Stare mnożniki:

```
1 disease_multiplier = 1.0 + (0.05 * citizen.num_conditions())
2 disease_multiplier += 0.10 * citizen.disability_score
3 risk_mult *= 1.3 # palenie
```

Nowe (zredukowane do podwójnego nieliczenia z tabelami GUS):

```
1 disease_multiplier = 1.0 + (0.02 * citizen.num_conditions())
2 disease_multiplier += 0.04 * citizen.disability_score
3 risk_mult *= 1.1 # palenie
```

8.3.6 Poprawka 6: zbyt silna redukcja płodności przez choroby

Stary kod pozwalał na redukcję płodności do zera. Dodano podest 0,7 ($\max(\cdot, 0,7)$).

8.3.7 Poprawka 7 (kluczowa): dodanie modelu Coxa + refaktor 3→2 chorób

- Hipercholesterolemia przeniesiona z chorób do RF (`high_cholesterol`). Biologicznie poprawne: sama nie powoduje objawów.
- Dodano `cumulative_hazard` do `Citizen`.
- Dodano 4 macierze parametrów do `DiseaseModel`.
- Przepisano `handle_deaths` na 3-fazowy model.

9 Aplikacja interaktywna (Streamlit)

9.1 Funkcjonalność

Plik: `interactive_simulation_app.py`. Uruchomienie:

```
1 streamlit run interactive_simulation_app.py
```

9.1.1 Kontrolki

- Rozmiar populacji: 1 000 – 100 000 (suwak)
- Czas symulacji: 5 – 50 lat
- Fertility multiplier (FM): 0,5 – 2,5
- Mortality multiplier (MM): 0,3 – 2,0
- **7 suwaków RF**: każdy 0,0 (eliminacja) – 3,0 (potrojenie); 1,0 = baseline.

9.1.2 Gotowe scenariusze

- **Healthy Population** — wszystkie RF = 0,5
- **High-Risk** — wszystkie RF = 1,5
- **Intervention** — wszystkie RF = 0,7
- **Anti-smoking** — tylko smoking = 0,3, reszta = 1,0

9.1.3 Wyniki i wizualizacje

- Metryki: populacja końcowa, survival rate, średni wiek.
- **Piramida wieku** (Plotly interaktywna).
- Prevalencja CVD i Lung Cancer (bar chart).
- Wpływ czynników ryzyka (sortowane wg HR).
- Trendy populacji w czasie (line chart).
- Tabela szczegółowych statystyk.
- Eksport wyników do JSON.

9.2 Przykładowe przypadki użycia

9.2.1 Kampania ograniczania palenia

- Population: 50 000
- Years: 50
- Smoking multiplier: 0,3 (redukcja 70 %)
- Inne RF: 1,0 (baseline)

Spodziewany wynik: znaczący spadek raka płuc, niższa zachorowalność CVD, wyższa populacja końcowa.

9.2.2 Interwencja lifestyle'owa

- Smoking 0,8, Obesity 0,7, Physical Inactivity 0,6
- Cholesterol 0,8, Hypertension 0,7, Alcohol 0,9
- Family History 1,0 (niemodyfikowalna)

Spodziewany wynik: znacząca poprawa zdrowia populacji, wyższy survival rate, niższy burden chorobowy.

10 Wnioski

10.1 Wnioski demograficzne

1. **Polska demografia jest deficytowa.** Przy naturalnych parametrach ($FM=MM=1,0$) populacja spada o $\sim 52\%$ przez 50 lat. Dla stabilności potrzeba $FM \approx 1,88$ przy $MM=1,0$ — prawie dwukrotnie wyższej płodności niż obecna.
2. **Asymetria wrażliwości.** Model reaguje silniej na zmiany MM niż na FM w dolnych zakresach. Przy bardzo niskiej MM (długie życie) nawet niska FM może dać stabilność.
3. **Kształt piramidy jest diagnostyczny.** Sama liczba populacji po 50 latach mówi mało; kształt piramidy ujawnia, czy się starzejemy, kurczymy u podstawy, czy mamy odpowiednią strukturę.
4. **Nadumieralność mężczyzn.** Wyraźnie widoczna w piramidach jako asymetria po wieku 50 r.ż. (kobiety żyją średnio 7,5 lat dłużej w Polsce).
5. **Punkt stabilności ABM** przy aktywnym modelu Coxa: $FM \approx 1,93$, $MM \approx 1,01$ (score = $-0,88\%$).

10.2 Wnioski epidemiologiczne

6. **Cox cumulative hazard rozdziela demografię od epidemiologii.** Bazowa tabela GUS modeluje populacyjne ryzyko zgonu w danym wieku; model Coxa nakłada na to indywidualne różnice z ekspozycji RF. Dwóch palaczy w wieku 60 może mieć różne ryzyko zgonu w zależności od historii ekspozycji.
7. **Palenie dominuje jako risk factor.** $HR=15$ dla raka płuc to największy współczynnik w macierzy. Palacze mają $\sim 16\times$ wyższe $H_{cum,LC}$ niż niepalący już po 10 latach symulacji. Polityki redukcji palenia mają największy potencjalny wpływ na śmiertelność z konkretnej przyczyny.
8. **Wielokrotne RF dla CVD.** Pięć czynników (palenie, hipertensja, hipercholesterolemia, otyłość, inactivity) odzwierciedla wielo-przyczynowość chorób sercowo-naczyniowych. Osoba z 3–4 z nich ma $\exp(\sum \beta) \approx 10\text{--}20\times$ wyższe ryzyko CVD.
9. **Refaktor 3→2 chorób był biologicznie poprawny.** Hipercholesterolemia sama w sobie nie jest chorobą powodującą zgon (oryginalna $DW = 0,08$ była bardzo niska). Jako risk factor wpływa pośrednio przez CVD ($HR=2,0$), co jest medycznie dokładniejsze.

10.3 Wnioski metodologiczne

10. **Kalibracja jest kluczowa.** Bez poprawek model dawał biologicznie niemożliwe wyniki (wszystkie scenariusze ujemne). Trzy błędy — odwrócona tabela + niskie TFR + zbyt silny wpływ chorób — wzmacniały się nawzajem.
11. **ABM wykrywa błędy niedostępne makromodelom.** Odwróconą tabelę kobiet odkryliśmy dzięki temu, że kobiety w wieku 65–75 umierały w modelu szybciej niż mężczyźni — diagnostyczny sygnał w piramidach.
12. **Równoległość jest niezbędna.** Każda symulacja ABM (50 000 agentów, 50 lat) trwa ~ 90 sekund. Bez ProcessPoolExecutor pełny gridsearch (144 symulacje) trwałby 3,5 godziny zamiast ~ 20 minut.

-
13. **Strategia 2-stopniowa: proxy $\rightarrow$ ABM.** Proxy (30 s) jako szybkie sito do orientacji w przestrzeni parametrów; ABM (50 min) do finalnej weryfikacji. Dla raportów: wyłącznie ABM. Stary proxy zostawiamy jako narzędzie diagnostyczne — jego rozbieżność z ABM identyfikuje regiony parametrów, gdzie efekty strukturalne dominują.
 14. **Proxy jest dokładny tylko w wąskim pasie wokół $MM \approx 1,0$** (tam, gdzie został skalibrowany). Poza tym pasem błąd dochodzi do 45–72 pp w score.

11 Ograniczenia i przyszłe rozszerzenia

11.1 Aktualne ograniczenia

- **Brak migracji.** Model jest demograficznie zamknięty — nie modeluje migracji wewnętrznej (między strefami) ani zagranicznej. W realnej Polsce migracja jest istotnym czynnikiem demograficznym.
- **Stałe tabele demograficzne.** Polska 2021 (GUS) jest używana niezmiennie przez 50 lat symulacji. W rzeczywistości tabele q_x i ASFR ewoluują — śmiertelność maleje (postęp medycyny), płodność reaguje na czynniki ekonomiczne i kulturowe.
- **RF statyczne.** W obecnym modelu RF są przyznawane raz przy tworzeniu agenta i nie zmieniają się. Realnie palenie można rzucić, otyłość można odwrócić — model nie ma mechanizmu *dynamic acquisition/loss*.
- **Tylko 2 choroby.** CVD i Lung Cancer to dominujące chronic diseases, ale model nie obejmuje cukrzycy, COPD, demencji, innych nowotworów.
- **Brak chorób zakaźnych.** Model jest skupiony na chorobach niezakaźnych (NCD). Nie modeluje epidemii (COVID-19, grypa) ani jej wpływu na demografię.
- **Heterogeniczność społeczno-ekonomiczna.** Strefy mają parametry środowiskowe (jakość powietrza, dostęp do opieki), ale ich wpływ na wyniki jest minimalny w obecnej kalibracji.

11.2 Możliwe rozszerzenia

- **RF progression pipeline.** Dynamiczne nabywanie RF, np. smoking $\rightarrow$ hypertension $\rightarrow$ CVD. Wymagałoby tabel transition probabilities między RF.
- **Intervention modeling.** Symulowanie konkretnych programów zdrowotnych — np. programów NFZ redukcji palenia, kampanii anty-otyłościowych. Możliwa analiza cost-benefit.
- **Spatial distribution.** Zróżnicowanie RF między strefami (np. miasto vs wieś), z migracją wewnętrzną i efektami kontekstualnymi.
- **Multi-disease interactions.** Choroby wzajemnie się wpływające — np. cukrzyca jako predyktor CVD; współwystępowanie raka i chorób kardiologicznych.
- **Cost-benefit analysis.** Wycena DALY (Disability-Adjusted Life Years) lub QALY (Quality-Adjusted Life Years) dla różnych interwencji.
- **Pełny gridsearch z aktywnym Coxem.** Obecny gridsearch 12×12 jest *bez* RF. Powtórzenie z aktywnymi RF dałoby nową regułę stabilności (przewidywana: FM $\approx 1,5 \cdot$ MM).

12 Technologie i implementacja

12.1 Stos technologiczny

Biblioteka	Zastosowanie
Python 3.12	Główny język
NumPy	Operacje numeryczne, <code>linspace</code> dla siatek
Plotly	Interaktywne wykresy HTML (piramidy, Sankey)
SciPy	<code>TwoSlopeNorm</code> dla heatmap
Matplotlib	Heatmapy gridsearch w PNG
<code>concurrent.futures</code>	Równoległe symulacje (<code>ProcessPoolExecutor</code>)
Streamlit	Aplikacja interaktywna
<code>random.Random</code>	Stochastyczność per agent z reproducibility

12.2 Dlaczego `random.Random`, a nie `numpy.random`?

Model jest *sekwencyjny per agent* — każdy agent losuje niezależnie w pętli. `random.Random` z seedem zapewnia pełną reproducibility. `numpy.random` jest lepszy dla operacji wektorowych (całe tablice naraz), co nie pasuje do ABM, gdzie każdy agent ma własny stan.

12.3 Reproducibility

Każda symulacja może być uruchomiona z konkretnym seedem (`random.Random(seed)`). Dzięki temu wyniki są deterministyczne i można je odtworzyć dla weryfikacji.

13 Bibliografia i źródła

- **GUS Polska.** Tablice Trwania Życia 2021. <https://stat.gov.pl>
- **GUS Polska.** Spis Powszechny 2021.
- **Program Białystok+.** Kohortowe dane medyczne populacji polskiej.
- **WHO.** Global Health Risks: Mortality and Burden of Disease Attributable to Selected Major Risks.
- **ESC** (European Society of Cardiology). Guidelines on cardiovascular disease prevention in clinical practice.
- **CDC.** Smoking & Tobacco Use — Health Effects.
- **IARC** (International Agency for Research on Cancer). Tobacco Smoking and Tobacco Smoke. Monograph 83.
- **GLOBOCAN 2020.** Global Cancer Observatory.
- **Framingham Heart Study.** Prospective cohort studies on cardiovascular disease risk factors.
- **ATP III** (Adult Treatment Panel III). Detection, Evaluation, and Treatment of High Blood Cholesterol.
- **AHA** (American Heart Association). Heart Disease and Stroke Statistics.
- **D.R. Cox** (1972). Regression Models and Life-Tables. JRSS Series B, 34(2):187–220.
- **B. Gompertz** (1825). On the nature of the function expressive of the law of human mortality. Philosophical Transactions of the Royal Society.